ОБЩЕСТВО С ОГРАНИЧЕННОЙ ОТВЕТСТВЕННОСТЬЮ
«ОНСОФТ»
ИНН 4800002685, КПП 480001001, ОГРН 1234800000522,
398001, г. Липецк, ул. Крайняя, 7а, пом. 20
e-mail: mail@on-soft.ru

Кейс ОНСОФТ: ИИ, который не обманывает

Задача для хакатона Школы 21, 7-9 ноября

Коротко

Вы спрашиваете ИИ, он отвечает уверенно и иногда обманывает: называет не то число, приводит цитату, которой нет в тексте, не замечает, что в двух документах написано разное. Задача: сделать ИИ-помощника, который обманывает как можно реже, и показать на цифрах, насколько стало лучше.

Программировать не обязательно. Подойдут и код, и готовые инструменты без программирования. Обучать свою модель не нужно.

Откуда задача

ОНСОФТ, ИТ-компания из Липецка, делает сервис для участников госзакупок. Перед участием менеджер читает документы закупки на 40-50 страниц и выписывает сроки, суммы и требования. Если ИИ ошибется хотя бы в одном числе, компания может проиграть закупку или получить штраф. Поэтому нам важен не просто ответ, а ответ, которому можно верить.

Все закупки, организации и суммы в данных выдуманы.

Что дано

Архив school21-onsoft-data.zip от организатора:

- packages/P01...P06: шесть закупок. В каждой 4-5 текстовых файлов: извещение, требования к заявке, описание работ, проект контракта, иногда изменения извещения.
- questions.csv: 71 вопрос к этим закупкам, например "Какой размер обеспечения заявки, в рублях?".
- answers_public.json: правильные ответы с цитатами, чтобы проверять себя.
- check.py: оценщик. Считает, сколько ответов верных, где ИИ честно сказал "не знаю", а где обманул. Нужен только Python, без библиотек.
- README.md: формат ответа и примеры запуска.

Среди вопросов есть ловушки, как в жизни:

- ответа в документах нет совсем;
- документ прямо говорит, что требования нет, хотя слово встречается;
- значение поменяли в изменениях извещения, и верное только новое;
- извещение и проект контракта противоречат друг другу.

Что сделать

Шаг 1. Замерить, как ИИ обманывает. Задайте модели вопросы "как есть", одним запросом, сохраните ответы в answers.csv и запустите python check.py answers.csv. Это ваша точка "было". Разберите 5-10 обманов: какие они бывают и почему.

Шаг 2. Сделать так, чтобы обманывал меньше. Добавьте проверки, которые ловят обман. Подойдет любой способ, например:

- требовать дословную цитату и проверять, что она есть в документе;

– проверять, что число из ответа есть в цитате;
– при ошибке задавать вопрос повторно и называть ошибку;
– разрешить модели отвечать "не знаю" и "нет в документах";
– давать модели нужный кусок документа, а не все сразу;
– попросить вторую модель или второй запрос проверить первый ответ.

Каждое изменение проверяйте оценщиком на той же модели: стало лучше или нет.

Шаг 3. Показать результат. График или дашборд "было/стало": индекс доверия и разбивка по типам вопросов. Плюс 2-3 примера обмана, который ваша система поймала, и как именно.

Уровень со звездочкой

Необязательная часть для сильных команд. Дает дополнительные баллы, но победить можно и без нее.

– Агентный цикл: ответ, проверки кодом, ИИ-критик, исправление и снова проверки, пока проверки не пройдут или не кончится бюджет запросов. Если не получилось, система честно пишет "не знаю".
– Несколько узких критиков вместо одного (по числам, по цитатам, по изменениям извещения) и замер, сколько дает каждый.
– Устойчивость к трудным файлам: инструкция, спрятанная в тексте документа; документ больше окна модели; файл в другой кодировке; пустой файл.

Формат ответа

Файл answers.csv, разделитель точка с запятой, по строке на вопрос:

id	status	answer	quote	file
P01-03	ответ	18000 руб.	18 000,00	01_izveshchenie.txt
P01-07	расхождение	60 и 75 дней	60 календарных дней	01_izveshchenie.txt
P01-13	нет в документах			
P02-05	не знаю			

– **ответ**: answer обязателен, числа пишите цифрами; quote должна дословно совпадать с текстом документа.
– **расхождение**: документы противоречат друг другу; в answer оба значения.
– **нет в документах**: вы уверены, что ответа в документах нет.
– **не знаю**: система не уверена.

Индекс доверия = (верных ответов - обманов) / всех вопросов x 100. Обман: неверное значение, цитата, которой нет в документах, ответ на то, чего в документах нет, или "нет в документах", когда ответ есть. "Не знаю" не добавляет и не отнимает баллы. Поэтому честное "не знаю" лучше уверенной ошибки.

Модели и инструменты

Подойдет любая модель: через API, локальная или в готовом сервисе. Сравнивайте "было" и "стало" на одной и той же модели, иначе непонятно, что дала ваша работа. Какие модели доступны на площадке, сообщит организатор.

Без программирования можно собрать сценарий в n8n, Dify, Flowise или похожем инструменте. Главное, чтобы ответы давала ваша система, а не человек вручную. На защите жюри задаст системе новый вопрос и посмотрит, как она отвечает.

Ключи доступа к моделям не кладите в код, презентацию и журнал.

Контрольный набор

В день защиты организатор выдаст новые закупки и около 100 новых вопросов того же вида, со своими ловушками. За отведенное время команда прогоняет систему без правок и сдает answers.csv. Жюри считает результат тем же check.py.

Что сдать

1. answers.csv на контрольном наборе.
2. Презентацию или дашборд с замером "было/стало" и разбором ошибок.
3. Описание: модель и версия, промпты, какие проверки сделаны, сколько запросов к модели и сколько времени уходит на один набор.
4. Код или экспорт сценария с инструкцией запуска.

Как оцениваем

Каждый член жюри ставит по каждому критерию оценку от 0 до 4: 0 нет результата, 1 существенные ошибки, 2 частично, 3 небольшие недостатки, 4 полностью. Баллы = вес критерия x оценка / 4.

Критерий	**Что проверяем**	**Вес**
Доверие на контрольном наборе	Индекс доверия по check.py на новых вопросах	30
Было/стало	Честный замер на одной модели, разбор типов обмана	25
Проверки	Что именно ловит обман, работает ли это на ловушках	15
Понятность	График или дашборд, понятно человеку без ИТ-образования	15
Воспроизводимость	Запуск по инструкции, модель и промпты описаны, ключей в коде нет	10
Уровень со звездочкой	Агентный цикл, узкие критики, трудные файлы	5
Итого		100

На каждой защите жюри спросит: "Покажите обман, который ваша система поймала, и как она его поймала".

Участников сильных команд пригласим на собеседование: у нас есть стажировка. Код и решения остаются у команд.

Генеральный директор
ООО «ОНСОФТ» Кисова Анна Евгеньевна
(должность) (подпись) (Ф.И.О.)

Тел. +7 950 800-41-63
Email: alexey@on-soft.ru